

Score Driven Models - Lista 1

Prof. Cristiano Fernandes

Alessandra Malizia

Setembro 2025

Questão 1

$$\begin{aligned}y_{t|t-1} &= \sigma_{t|t-1} \cdot \epsilon_t & \epsilon_t &\sim t(0, 1, \nu) \\ \sigma_{t+1|t}^2 &= \omega + \alpha y_t^2\end{aligned}$$

Item a) Momentos condicionais

A distribuição condicional é simétrica e possui valor esperado e coeficiente de simetria condicionais iguais a zero. Já a variância condicional é dada pela variância do modelo ARCH e do erro, que segue uma distribuição t-student. O coeficiente de curtose é maior que 3, indicando que a distribuição é leptocúrtica.

a) obter $E(y_t | y_{t-1})$, $\text{Var}(y_t | y_{t-1})$, $S(y_t | y_{t-1})$, $K(y_t | y_{t-1})$

(1) simetria

(2) kurtose

$$\begin{aligned} \text{(i)} \quad E(y_t | y_{t-1}) &= E(\sigma_{t|t-1} \cdot \epsilon_t | y_{t-1}) \\ &= \sigma_{t|t-1} \cdot E(\epsilon_t | y_{t-1}) \\ &= 0 \end{aligned}$$

$$\begin{aligned} \text{(ii)} \quad \text{Var}(y_t | y_{t-1}) &= \sigma_{t|t-1}^2 \text{Var}(\epsilon_t | y_{t-1}), \quad \nu > 2 \\ &= \sigma_{t|t-1}^2 \frac{\nu}{\nu-2} \end{aligned}$$

$$\begin{aligned} \text{(iii)} \quad S(y_t | y_{t-1}) &= \sigma_{t|t-1}^3 \cdot S(\epsilon_t | y_{t-1}), \quad \nu > 3 \\ &= 0 \end{aligned}$$

$$\begin{aligned} \text{(iv)} \quad K(y_t | y_{t-1}) &= \sigma_{t|t-1}^4 \cdot K(\epsilon_t | y_{t-1}) \cdot \frac{1}{\text{Var}(y_t)^2}, \quad \nu > 4 \\ &= \frac{3\nu^2}{(\nu-2)(\nu-4)} \cdot \frac{(\nu-2)^2}{\nu^2} = \frac{3(\nu-2)}{(\nu-4)} \Rightarrow K(y_t | y_{t-1}) = 3 + \frac{6}{\nu-4} \end{aligned}$$

Item b) Distribuição condicional

A distribuição condicional é uma t generalizada com ν graus de liberdade e escala dada pela variância do modelo. A densidade possui a mesma forma da distribuição do erro, que é uma t com escala igual a 1.

b) Derivar $p(y_t | y_{t-1})$

$$\epsilon_t \sim t(0, 1, \nu)$$

$$y_t = \sigma_{t|t-1} \epsilon_t$$

$$p(\epsilon_t) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\pi\nu} \Gamma(\frac{\nu}{2})} (1 + \epsilon_t^2/\nu)^{-\frac{\nu+1}{2}}$$

$$p(y_t) = p(\epsilon_t) \left| \frac{dy_t}{d\epsilon_t} \right|$$

$$= \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\pi\nu} \Gamma(\frac{\nu}{2})} \left(1 + \frac{y_t^2}{\sigma_{t|t-1}^2 \nu} \right)^{-\frac{\nu+1}{2}} \cdot \frac{1}{\sigma_{t|t-1}}$$

$$\Rightarrow p(y_t | y_{t-1}) \sim t(0, \sigma_{t|t-1}^2, \nu)$$

Item c) Momentos incondicionais

Assim como o valor esperado e coeficiente de simetria condicionais, o valor esperado e o coeficiente de simetria incondicionais são iguais a zero. A variância e o coeficiente de curtose são obtidos por recursividade a partir das equações do modelo e convergem para um valor constante quando t tende a infinito e o modelo é estacionário, ou seja, $\alpha < \frac{\nu}{\nu-2}$.

c) Derivar $E(y_t)$, $Var(y_t)$, $S(y_t)$ e $K(y_t)$

$$\bullet E(y_t) = E(E(y_t | y_{t-1})) = 0$$

$$\bullet S(y_t) = E(y_t^3) = E(\sigma_{t|t-1}^3 \cdot \epsilon_t^3) = E(\sigma_{t|t-1}^3) \cdot E(\epsilon_t^3), \quad \nu > 3$$

$$= 0$$

c) continuação

$$\begin{aligned} \text{Var}(y_t) &= E(y_t^2) \\ &= E(\sigma_{t+1}^2 \cdot \epsilon_t^2) \\ &= E(\omega + \alpha y_{t-1}^2) \cdot E(\epsilon_t^2) \\ &= (\omega + \alpha E(y_{t-1}^2)) \cdot \underbrace{\frac{N}{N-2}}_K \\ &= \dots \end{aligned}$$

$$\begin{aligned} \Rightarrow \text{Var}(y_t) &= K\omega + K\alpha(K\omega + K\alpha E(y_{t-2}^2)) \\ &= K\omega + K\alpha K\omega + K^2\alpha^2 E(y_{t-2}^2) \\ &= K\omega + K\alpha K\omega + K^2\alpha^2 K\omega + K^3\alpha^3 E(y_{t-3}^2) \\ &= K\omega(1 + K\alpha + K^2\alpha^2) + K^3\alpha^3 E(y_{t-3}^2) \\ &\dots \end{aligned}$$

$$\begin{aligned} &= K\omega(1 + K\alpha + K^2\alpha^2 + \dots + K^{t-2}\alpha^{t-2}) + K^{t-1}\alpha^{t-1} E(y_1^2) \\ &= K\omega(1 + K\alpha + \dots + K^{t-2}\alpha^{t-2}) + K^{t-1}\alpha^{t-1} \sigma_1^2 \end{aligned}$$

$$\Rightarrow \text{Var}(y_t) = \frac{N\omega}{N-2} \left(\sum_{i=0}^{t-2} \left(\frac{\alpha N}{N-2} \right)^i \right) + \left(\frac{N}{N-2} \right)^{t-1} \alpha^{t-1} \sigma_1^2$$

c) continuação

$$\text{Var}(y_t) = \frac{N\omega}{N-2} \left(\sum_{i=0}^{t-2} \left(\frac{\alpha N}{N-2} \right)^i \right) + \left(\frac{N}{N-2} \right)^{t-1} \alpha^{t-1} \sigma_1^2$$

Quando $\alpha < \frac{N-2}{N}$ e $t \rightarrow \infty$, $\left(\frac{\alpha N}{N-2} \right)^i < 1$

$$\Rightarrow \text{Var}(y_t) = \frac{N\omega}{N-2} \cdot \frac{1}{1 - \frac{\alpha N}{N-2}} = \frac{N\omega}{N(1-\alpha) - 2}$$

$$\begin{aligned}
 \bullet K(y_t) &= E(y_t^4) = E(\sigma_{1t-1}^4) \cdot E(\epsilon_t^4) \\
 &= \left(\frac{3\nu^2}{(\nu-2)(\nu-4)} \right) \cdot E(\omega^2 + 2\alpha\omega y_{t-1}^2 + \alpha^2 y_{t-1}^4) \\
 &= K(\omega^2 + 2\alpha\omega \text{Var}(y_{t-1}) + \alpha^2 E(y_{t-1}^4)) \\
 &= K\omega^2 + 2K\alpha\omega \text{Var}(y_{t-1}) + K\alpha^2 (K\omega^2 + 2K\alpha\omega \text{Var}(y_{t-2}) + K\alpha^2 E(y_{t-2}^4)) \\
 &= K\omega^2 (1 + K\alpha^2) + 2K\alpha\omega (\text{Var}(y_{t-1}) + K\alpha^2 \text{Var}(y_{t-2})) + K^2\alpha^4 E(y_{t-2}^4) \\
 &= (1 + K\alpha^2) (K\omega^2 + 2K\alpha\omega \sum_{i=1}^{t-2} \text{Var}(y_{t-i})) + K^2\alpha^4 E(y_{t-2}^4) \\
 &= \sum_{i=0}^{t-3} (K\alpha^2)^i \cdot K\omega^2 + 2K\alpha\omega \sum_{i=1}^{t-2} (K\alpha^2)^{i-1} \text{Var}(y_{t-i}) + (K\alpha^2)^{t-2} E(y_1^4) \\
 E(y_t^4) &= \sigma_1^4 \cdot K(\epsilon_t) = \sigma_1^4 \cdot \left(\frac{3\nu^2}{(\nu-2)(\nu-4)} \right) = K\sigma_1^4
 \end{aligned}$$

$$\bullet K(y_t) = \sum_{i=0}^{t-3} (K\alpha^2)^i (K\omega^2 + 2K\alpha\omega \sigma^2) + (K\alpha^2)^{t-2} \cdot K\sigma_1^4, \quad K = \frac{\nu}{\nu-2}$$

$$\frac{3(\nu-2)}{3\nu-4} \alpha^2 < 1 \Rightarrow \alpha^2 < \frac{\nu-4}{3(\nu-2)}$$

Quando $t \rightarrow \infty$

$$\begin{aligned}
 K(y_t) &= (K\omega^2 + 2K\alpha\omega \sigma^2) \frac{1}{1 - K\alpha^2} \\
 &= \left(\frac{3\nu^2\omega^2}{(\nu-2)(\nu-4)} + \frac{6\nu^2\alpha\omega}{(\nu-2)(\nu-4)} \cdot \frac{\nu\omega}{(\nu-\nu-2)} \right) \cdot \frac{1}{1 - \frac{3\nu^2\alpha^2}{(\nu-2)(\nu-4)}} \\
 &= \frac{3\nu^2\omega^2(\nu + 2\nu - 2)}{((\nu-4)(\nu-2) - 3\nu^2\alpha^2)} \cdot \frac{1}{(\nu - \alpha\nu - 2)}
 \end{aligned}$$

$$\Rightarrow K(y_t) = \frac{3\nu^2\omega^2(\nu + 2\nu - 2)}{((\nu-4)(\nu-2) - 3\nu^2\alpha^2)} \cdot \frac{1}{\nu - \alpha\nu - 2}$$

$$= \frac{3(\alpha^2\nu^2 - (\nu-2)^2)}{3\alpha^2\nu^2 - (\nu-4)(\nu-2)}$$

Item d) Distribuição incondicional

Para obter a densidade incondicional $p(y_t)$, é necessário integrar a densidade de probabilidade condicional $p(y_t|y_{t-1})$ sobre a variável y_{t-1} . Ao substituir recursivamente as equações do modelo na função de densidade condicional, é possível observar que a função na integral adquire uma forma complexa, que não é possível resolver analiticamente.

d) Mostre que $p(y_t)$ não possui forma analítica explícita

$$\begin{aligned}
 p(y_t|y_{t-1}) &= \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})\sqrt{\pi}\sigma_{t|t-1}} \left(1 + \frac{y_t^2}{\sigma_{t|t-1}^2}\right)^{-\frac{(\nu+1)}{2}} \\
 &= \underbrace{\frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2})\sqrt{\pi}\sigma_{t|t-1}}}_K \cdot \frac{1}{(\omega + \alpha y_{t-1}^2)^{1/2}} \left(1 + \frac{y_t^2}{\sigma_{t|t-1}^2}\right)^{-\frac{(\nu+1)}{2}} \\
 &= K \cdot \frac{1}{(\omega + \alpha \sigma_{t-1|t-1}^2)^{1/2}} \left(1 + \frac{y_t^2}{\sigma_{t-1|t-1}^2}\right)^{-\frac{(\nu+1)}{2}} \\
 \Rightarrow p(y_t) &= \int p(y_t|y_{t-1}) p(y_{t-1}) dy_{t-1}
 \end{aligned}$$

Item e) Correlações

A correlação linear é nula, pois não há dependência linear de y_t com seus lags no modelo. Já a correlação quadrática é positiva e decai com o tempo, proporcional a α^k . Esse resultado é explicado pela presença de dependência quadrática no modelo e é determinado pela persistência da volatilidade na equação (2).

i) Linear

e) Autokor

$$(i) \varphi_y(k) = \text{cov}(y_t, y_{t-k})$$

$$(ii) \varphi_{y^2}(k) = \text{cov}(y_t^2, y_{t-k}^2)$$

(i)

$$\begin{aligned} \text{cov}(y_{t+k}, y_t) &= E(y_{t+k} \cdot y_t) \\ &= E(\sigma_{t+k|t+k-1} \cdot \epsilon_{t+k} \cdot \sigma_t \cdot \epsilon_t) \\ &= E(\sigma_{t+k|t+k-1} \cdot \sigma_t) E(\epsilon_{t+k} \cdot \epsilon_t) \\ &= 0 \end{aligned}$$

$$\Rightarrow \varphi_y(k) = \text{cov}(y_{t+k}, y_t) = \frac{\text{cov}(y_{t+k}, y_t)}{\sqrt{\text{Var}(y_{t+k}) \text{Var}(y_t)}} = 0$$

ii) Quadrática

$$\begin{aligned}
 (ii) \text{ cov}(y_{t+k}^2, y_t^2) &= E((y_{t+k}^2 - \text{Var}(y_{t+k}))(y_t^2 - \text{Var}(y_t))) \\
 &= E(y_{t+k}^2 y_t^2 - \text{Var}(y_t) y_{t+k}^2 - \text{Var}(y_{t+k}) y_t^2 + \text{Var}(y_t) \text{Var}(y_{t+k})) \\
 &= E(y_{t+k}^2 y_t^2) - \text{Var}(y_t) E(y_{t+k}^2) - \text{Var}(y_{t+k}) E(y_t^2) + \text{Var}(y_t) \text{Var}(y_{t+k}) \\
 &= E(y_{t+k}^2 y_t^2) - \text{Var}(y_t) \text{Var}(y_{t+k})
 \end{aligned}$$

$$\begin{aligned}
 \bullet y_{t+k}^2 &= \sigma_{t+k|t+k-1}^2 \cdot \epsilon_{t+k}^2 \\
 &= \epsilon_{t+k}^2 (\omega + \alpha y_{t+k-1}^2) \\
 &= \epsilon_{t+k}^2 (\omega + \alpha (\epsilon_{t+k-1}^2 (\omega + \alpha y_{t+k-2}^2))) \\
 &= \epsilon_{t+k}^2 \omega + \alpha \epsilon_{t+k}^2 \omega + \alpha^2 \epsilon_{t+k}^2 \epsilon_{t+k-1}^2 y_{t+k-2}^2 \\
 &= \omega (\epsilon_{t+k}^2 + \alpha \epsilon_{t+k-1}^2 + \alpha^2 \epsilon_{t+k}^2 \epsilon_{t+k-1}^2 \epsilon_{t+k-2}^2) + \alpha^3 \epsilon_{t+k}^2 \epsilon_{t+k-1}^2 \epsilon_{t+k-2}^2 y_{t+k-3}^2 \\
 &= \omega \sum_{i=0}^{k-1} \alpha^i \prod_{j=0}^{i-1} \epsilon_{t+k-j}^2 + \alpha^k \prod_{i=0}^{k-1} \epsilon_{t+k-i}^2 y_t^2
 \end{aligned}$$

$$\Rightarrow E(y_{t+k}^2 y_t^2) = \omega \sum_{i=0}^{k-1} \alpha^i \sigma_\epsilon^{2i+1} \text{Var}(y_t) + \alpha^k \sigma_\epsilon^{2k} E(y_t^4)$$

$$\text{Var}(y_{t+k}) = \omega \sum_{i=0}^{k-1} \alpha^i \sigma_\epsilon^{2i+1} + \alpha^k \sigma_\epsilon^{2k} \text{Var}(y_t) \quad (\times \text{Var}(y_t))$$

$$\Rightarrow \text{cov}(y_{t+k}^2, y_t^2) = \alpha^k \sigma_\epsilon^{2k} (K(y_t) - \text{Var}(y_t)^2)$$

1e)

ii) continuação

$$\Rightarrow \text{cov}(y_{t+k}^2, y_t^2) = \alpha^k \sigma_\epsilon^{2k} \left(\frac{K(y_t)}{\text{Var}(y_t)^2} - 1 \right)$$

$$= \alpha^k \left(\frac{\nu}{\nu-2} \right)^k \left(\frac{3(\alpha^2 \nu^2 - (\nu-2)^2)}{3\alpha^2 \nu^2 - (\nu-2)(\nu-4)} - 1 \right)$$

$$= \alpha^k \left(\frac{\nu}{\nu-2} \right)^k \left(\frac{(\nu-2)(\nu-4) - 3(\nu-2)^2}{3\alpha^2 \nu^2 - (\nu-2)(\nu-4)} \right)$$

$$= \frac{\alpha^k \nu^k \cdot 2(\nu-2)(\nu-1)}{(\nu-2)^k ((\nu-2)(\nu-4) - 3\alpha^2 \nu^2)}$$

$$\Rightarrow \text{cov}(y_{t+k}^2, y_t^2) = \frac{2 \alpha^k \nu^k (\nu-1)}{(\nu-2)^{k-1} ((\nu-2)(\nu-4) - 3\alpha^2 \nu^2)}$$

Item f) Momentos da densidade preditiva

f) Alter

(i) $E(y_{t+k} | y_t)$

(ii) $E(k \text{ Var}(y_{t+k} | y_t))$

(i) $E(y_{t+k} | y_t) = E_t(\sigma_{t+k|t+k-1} \cdot \epsilon_{t+k})$

$$= E_t E_{t+1} \dots E_{t+k-1}(\sigma_{t+k|t+k-1} \cdot \epsilon_{t+k})$$

$$= E_t E_{t+1} \dots E_{t+k-2}(\sigma_{t+k|t+k-1} \cdot E_{t+k-1}(\epsilon_{t+k}))$$

$$= 0$$

(ii) $\text{Var}(y_{t+k} | y_t) = E(y_{t+k}^2 | y_t)$

$$= E(\omega \sum_{i=0}^{k-1} \alpha^i \prod_{j=0}^i \epsilon_{t+k-j}^2 + \alpha^k \prod_{i=0}^{k-1} \epsilon_{t+k-i}^2 y_t^2 | y_t)$$

$$= \omega \sum_{i=0}^{k-1} \alpha^i \sigma_e^{i+1} + \alpha^k \sigma_e^k y_t^2$$

Item g) Densidade preditiva

Para $k=1$, a função de densidade preditiva possui uma forma bem definida e segue uma distribuição t .

Já para $k=2$, é possível obter a densidade preditiva por marginalização. Ao desenvolver o cálculo da expressão na integral, é obtida uma equação em que as densidades t são funções da escala $\sigma_{t+2|t+1}$, que por sua vez depende da variável de integração y_{t+1} . Dessa forma, não é possível resolver a integral para obter uma forma analítica da densidade preditiva.

g) Mostre que $p(y_{t+k}|y_t)$ não possui forma analítica

$p/K=1: p(y_{t+1}|y_t) \sim t(0, \sigma_{t+1|t}^2, \nu)$

$p/K \gg 2:$

$$p(y_{t+2}|y_t) = \int \frac{1}{\sigma_{t+2|t+1}} f_t\left(\frac{y_{t+2}}{\sigma_{t+2|t+1}}; \nu\right) \cdot \frac{1}{\sigma_{t+1|t}} f_t\left(\frac{y_{t+1}}{\sigma_{t+1|t}}; \nu\right) dy_{t+1}$$


Item h) Simulação

Usando os parâmetros arbitrariamente escolhidos para satisfazer a existência de todos os momentos calculados e a condição de estacionariedade, os coeficientes de simetria amostrais obtidos foram -0.47 e 0.02 para $k=3$ e $k=30$, respectivamente. Esses valores são próximos ao valor teórico calculado e indicam que a distribuição é simétrica.


Para $k=3$, o coeficiente de curtose obtido em $t=200$ foi $K=21$. A grande diferença do resultado obtido para o valor teórico do coeficiente de curtose do erro indica que nesse horizonte o processo possui caudas mais pesadas que uma distribuição t . Já para $k=30$, o coeficiente de curtose calculado foi 8.3, mais próximo da curtose de uma $t(5)$. Esse resultado indica que em horizontes maiores a ocorrência de valores extremos é suavizada, e a distribuição tende à densidade incondicional.

Skewness: -0.47

Kurtosis: 21.28



Skewness: 0.02
Kurtosis: 8.27



```
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.ticker import PercentFormatter
import scipy.stats as stats
import seaborn as sns
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
import yfinance as yf
from arch import arch_model
import pandas as pd

rng = np.random.default_rng(seed=4)

# simulação da série do modelo
nu = 5
omega, alpha = 1, 0.2
T = 200
y1 = 5

epsilont = rng.standard_t(df=nu, size=T)
yt = np.zeros(T)
yt[0] = y1

for i in range(1, T):
    sigma2 = omega + alpha * yt[i-1]**2
    yt[i] = sigma2**0.5 * epsilont[i]

series = yt.copy()

# simulação da densidade preditiva
```

```

k = 3
N = 10000

y_hat = np.zeros((T+k,N))

for t in range(T):
    y_curr = np.full(N, series[t])
    epsilon_t = rng.standard_t(df=nu, size=(k,N))

    for i in range(k):
        sigma2_hat = omega + alpha * y_curr**2
        y_curr = sigma2_hat**0.5 * epsilon_t[i]

    y_hat[t+k] = y_curr

# histograma
print(f'Skewness: {stats.skew(y_hat[T-1+k]):.2f}')
print(f'Kurtosis: {stats.kurtosis(y_hat[T-1+k]) + 3:.2f}')

fig, ax = plt.subplots(figsize=(10,4))
ax.hist(y_hat[T-1+k], bins=20)
ax.set_title('Histograma da densidade preditiva para t=200 e k=3')
plt.show()

```

Item i) Log verossimilhança

i) Obtenha log likelihood




$$y_t = \sigma_{t|t-1} \cdot \epsilon_t, \quad \epsilon_t \sim t(0, 1, \nu)$$
$$p(y_t | y_{t-1}) \sim t(0, \sigma_{t|t-1}^2, \nu)$$
$$\Rightarrow p(y_t | y_{t-1}) = \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2}) \sigma_{t|t-1} \sqrt{\pi \nu}} \left(\frac{1 + \frac{y_t^2}{\sigma_{t|t-1}^2 \nu}}{2} \right)^{-\frac{(\nu+1)}{2}}$$
$$L(\theta) = \prod_{t=1}^T p(y_t | y_{t-1}), \quad \theta = (\nu, \sigma_{1|0})$$
$$l(\theta) = \ln L(\theta) = \sum_{t=1}^T \ln p(y_t | y_{t-1})$$
$$\Rightarrow l(\theta) = \sum_{t=1}^T \ln \left(\frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2}) \sigma_{t|t-1} \sqrt{\pi \nu}} \left(\frac{1 + \frac{y_t^2}{\sigma_{t|t-1}^2 \nu}}{2} \right)^{-\frac{(\nu+1)}{2}} \right)$$
$$= T \ln \frac{\Gamma(\frac{\nu+1}{2})}{\Gamma(\frac{\nu}{2}) \sqrt{\pi \nu}} + \sum_{t=1}^T \ln \sigma_{t|t-1}^2 - \frac{(\nu+1)}{2} \sum_{t=1}^T \ln \left(\frac{1 + \frac{y_t^2}{\sigma_{t|t-1}^2 \nu}}{2} \right) \quad ||$$

Item j) Retornos diários

Foi ajustado um modelo ARCH(1) com erro $\epsilon_t \sim t(0, 1, \nu)$ à série de retornos diários das ações da Apple. Foram usados dados desde Jun/2016 e variações percentuais do valor da ação.

A FAC dos resíduos padronizados não possui valores significativos de autocorrelação nos lags, indicando que não há dependência linear e que o modelo capturou bem essa dinâmica da série. Já a FAC dos resíduos ao quadrado possui valores significativos e indica a existência de heterocedasticidade.

Esse resultado sugere que ainda há dependência de segunda ordem na volatilidade que não foi capturada pelo modelo, o que pode ser esperado de um modelo simples ARCH(1). Esse modelo pode ser melhorado incluindo lags da variância e estimando um ARCH(p,q).



Constant Mean - ARCH Model Results

```

=====
Dep. Variable:          Price      R-squared:          0.000
Mean Model:            Constant Mean  Adj. R-squared:      0.000
Vol Model:             ARCH        Log-Likelihood:    -4453.71
Distribution:          Standardized Student's t  AIC:              8915.41
Method:               Maximum Likelihood  BIC:              8938.44
                                           No. Observations:  2339
Date:                 Sun, Sep 21 2025  Df Residuals:      2338
Time:                 15:36:40         Df Model:           1
                                           Mean Model
=====

```

```

=====
              coef      std err          t      P>|t|      95.0% Conf. Int.
-----
mu          -0.1455   2.836e-02     -5.128   2.923e-07 [ -0.201, -8.987e-02]
              Volatility Model
=====

```

```

=====
              coef      std err          t      P>|t|      95.0% Conf. Int.
-----
omega         2.5000      0.203     12.308   8.240e-35 [  2.102,  2.898]
alpha[1]       0.3863   6.956e-02      5.553   2.803e-08 [  0.250,  0.523]
              Distribution
=====


```

```

=====
              coef      std err          t      P>|t|      95.0% Conf. Int.
-----
nu             3.5767      0.277     12.907   4.119e-38 [  3.034,  4.120]
=====

```

Resíduos padronizados



```

import numpy as np
import matplotlib.pyplot as plt
from matplotlib.ticker import PercentFormatter
import scipy.stats as stats
import seaborn as sns
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
import yfinance as yf

```

```

from arch import arch_model
import pandas as pd

# importação de dados
series = pd.read_csv('C:\\Users\\aless\\Downloads\\Apple Stock Price History.csv')[['Date', 'Close']]
series.index = pd.to_datetime(series.index)

returns = series.pct_change().mul(100).dropna().loc['2016-06:']

# estimação do modelo
model = arch_model(returns, vol='GARCH', p=1, q=0, dist='t', mean='Constant')
res = model.fit(dispatch='off')
print(res.summary())

std_resid = res.std_resid.dropna()

# figuras
fig, ax = plt.subplots(figsize=(8,3))
ax.plot(returns)
ax.set_title('Variação percentual diária dos preços da ação AAPL')
ax.set_ylabel('(p.p.)')
plt.savefig('C:\\Users\\aless\\Desktop\\Codes\\masters\\SDM\\img\\retornos.jpg', dpi=300, bbox_inches='tight')
plt.show()

fig, ax = plt.subplots(figsize=(8,3))
ax.plot(std_resid)
ax.set_title('Resíduos padronizados')
plt.savefig('C:\\Users\\aless\\Desktop\\Codes\\masters\\SDM\\img\\resíduos.jpg', dpi=300, bbox_inches='tight')
plt.show()

fig, ax = plt.subplots(figsize=(8,3))
plot_acf(std_resid**2, ax=ax, title='FAC dos resíduos ao quadrado')
plt.savefig('C:\\Users\\aless\\Desktop\\Codes\\masters\\SDM\\img\\FAC.jpg', dpi=300, bbox_inches='tight')
plt.show()

```

Questão 2

item a) Erro aditivo

i)

A densidade preditiva tem a mesma forma do erro ϵ_t e segue uma distribuição Gamma generalizada, deslocada em $g_{t|t-1}$.

$$ii) \epsilon_t \sim \text{gama}(\mu, \theta), \mu = E(\epsilon_t)$$

$$p(\epsilon_t) = \frac{1}{\Gamma(\frac{\mu}{\theta}) \theta^{\mu/\theta}} \epsilon_t^{\mu/\theta - 1} e^{-\epsilon_t/\theta}, \quad \epsilon_t > 0$$

$$p(y_t | y_{t-1}) = p(\epsilon_t) \bigg|_{\epsilon_t = y_t - g_{t|t-1}} \cdot \frac{1}{\left| \frac{dy_t}{d\epsilon_t} \right|}$$

$$= \frac{1}{\Gamma(\frac{\mu}{\theta}) \theta^{\mu/\theta}} (y_t - g_{t|t-1})^{\mu/\theta - 1} e^{-\frac{(y_t - g_{t|t-1})}{\theta}}$$

$$\Rightarrow p(y_t | y_{t-1}) \sim \text{gama}(\mu, \theta, g_{t|t-1}), \quad y_t > g_{t|t-1}$$

ii)

A densidade preditiva tem a forma da distribuição de Poisson do erro ϵ_t , deslocada em $g_{t|t-1}$.

$$iii) \epsilon_t \sim \text{Poisson}(\lambda)$$

$$p(\epsilon_t) = \frac{\lambda^{\epsilon_t} e^{-\lambda}}{\epsilon_t!}, \quad \epsilon_t \in \mathbb{N}_0$$

$$\Rightarrow p(y_t | y_{t-1}) = p(\epsilon_t) \bigg|_{\epsilon_t = y_t - g_{t|t-1}} \cdot \frac{1}{\left| \frac{dy_t}{d\epsilon_t} \right|}$$

$$= \frac{\lambda^{(y_t - g_{t|t-1})} e^{-\lambda}}{(y_t - g_{t|t-1})!}$$

$$\Rightarrow p(y_t | y_{t-1}) \sim \text{poisson}(\lambda), \quad y_t \geq g_{t|t-1} \geq 0$$

iii)

A densidade preditiva segue a mesma distribuição Beta do erro, definida em $g_{t|t-1} < y_t < g_{t|t-1} + a$.

$$\begin{aligned}
 \text{iii) } \epsilon_t &\sim \text{Beta}(\alpha, \beta), \quad \epsilon_t \in (0, a) \\
 p(\epsilon_t) &= \frac{(\epsilon_t/a)^{\alpha-1} (1 - \epsilon_t/a)^{\beta-1}}{a \cdot B(\alpha, \beta)} \\
 p(y_t | y_{t-1}) &= p(\epsilon_t) \cdot \left| \frac{dy_t}{d\epsilon_t} \right| \\
 &\quad \epsilon_t = y_t - g_{t|t-1} \\
 &= \frac{\left(\frac{y_t - g_{t|t-1}}{a} \right)^{\alpha-1} \cdot \left(1 - \frac{y_t - g_{t|t-1}}{a} \right)^{\beta-1}}{a \cdot B(\alpha, \beta)} \\
 \Rightarrow p(y_t | y_{t-1}) &\sim \text{Beta}(\alpha, \beta), \quad g_{t|t-1} < y_t < g_{t|t-1} + a
 \end{aligned}$$

item b) Erro multiplicativo

i)

A densidade preditiva segue uma distribuição exponencial com $\lambda = \lambda_\epsilon / g_{t|t-1}$.

$$i) \epsilon_t \sim \exp(\lambda)$$

$$p(\epsilon_t) = \lambda e^{-\lambda \epsilon_t}, \quad \epsilon_t > 0$$

$$p(y_t | y_{t-1}) = p(\epsilon_t) \cdot \left| \frac{dy}{d\epsilon_t} \right|$$

$$\epsilon_t = y_t / g_{t|t-1}$$

$$= \frac{\lambda e^{-\lambda \epsilon_t / g_{t|t-1}}}{g_{t|t-1}}$$

$$\Rightarrow p(y_t | y_{t-1}) \sim \exp(-y_t / g_{t|t-1})$$

ii)

A densidade preditiva não pertence à mesma família da distribuição de ϵ_t .

$$ii) \epsilon_t \sim \text{gamma}(\mu, \theta)$$

$$p(\epsilon_t) = \frac{1}{\Gamma(\frac{\mu}{\theta}) \theta^{\mu/\theta}} \epsilon_t^{\mu/\theta - 1} e^{-\epsilon_t / \theta}, \quad \epsilon_t > 0$$

$$p(y_t | y_{t-1}) = p(\epsilon_t) \cdot \left| \frac{dy}{d\epsilon_t} \right|$$

$$\epsilon_t = y_t / g_{t|t-1}$$

$$= \frac{1}{\Gamma(\frac{\mu}{\theta}) \theta^{\mu/\theta}} \left(\frac{y_t}{g_{t|t-1}} \right)^{\mu/\theta - 1} e^{-y_t / \theta g_{t|t-1}} \cdot \frac{1}{g_{t|t-1}}$$

$$= \frac{1}{\Gamma(\frac{\mu}{\theta}) (\theta g_{t|t-1})^{\mu/\theta}} y_t^{\mu/\theta - 1} e^{-y_t / \theta g_{t|t-1}}$$

iii)

Handwritten mathematical derivation on lined paper:

$$\text{iii) } \epsilon_t \sim \text{Poisson}(\lambda)$$
$$p(\epsilon_t) = \frac{\lambda^{\epsilon_t} e^{-\lambda}}{\epsilon_t!}$$
$$p(y_t | y_{t-1}) = p(\epsilon_t = y_t - y_{t-1})$$
$$= \frac{\lambda^{y_t - y_{t-1}} e^{-\lambda}}{\left(\frac{y_t}{y_{t-1}}\right)!}$$

A densidade preditiva não pertence à mesma família da distribuição de ϵ_t .