

Score Driven Models - Lista 2

Prof. Cristiano Fernandes

Alessandra Malizia

Novembro de 2025

Questão 1

$$p(y_t|y_{t-1}) \sim NB(\mu, r)$$

Item a) Parametrização e momentos da distribuição

$$1a) p(y_t | y_{t-1}) \sim NB(\mu, r) \quad , \quad r > 0 \text{ e } \mu > 0 \quad (1)$$

$$\bullet E(y_t | y_{t-1}) = \mu_{t+1} //$$

$$\mu = \frac{r(1-p)}{p} \Rightarrow \mu p + r p = r \Rightarrow p = \frac{r}{\mu + r} \quad , \quad 1-p = \frac{\mu}{\mu + r}$$

$$\bullet \text{Var}(y_t | y_{t-1}) = \frac{\mu_t}{p} = \frac{\mu(\mu + r)}{r}$$

$$\bullet S(y_t | y_{t-1}) = \frac{2-p}{\sqrt{(1-p)r}} = \left(2 - \frac{r}{\mu + r}\right) \sqrt{\frac{(\mu + r)}{\mu r}}$$

$$\Rightarrow S(y_t | y_{t-1}) = \frac{2\mu + r}{\sqrt{(\mu + r)\mu r}}$$

$$\begin{aligned} \bullet K(y_t | y_{t-1}) &= 3 + \frac{6}{r} + \frac{p^2}{(1-p)r} = 3 + \frac{6}{r} + \frac{r^2}{(\mu + r)^2} \cdot \frac{(\mu + r)}{\mu r} \\ &= 3 + \frac{6\mu(\mu + r) + r^2}{(\mu + r)\mu r} \end{aligned}$$

$$\Rightarrow p(y_t | y_{t-1}) = \binom{y_t + r - 1}{y_t} \left(\frac{\mu}{\mu + r}\right)^{y_t} \left(\frac{r}{\mu + r}\right)^r$$

Item b) Equação da média com GAS(p,q)

i) Link identidade

b) i) (1) link identidade

$$\mu_{t+1|t} = \omega + \sum_{i=1}^p \alpha_i \mu_{t-i+1|t-i} + \sum_{j=1}^q \beta_j \Delta_{t-j+1}, \quad \Delta_t = (I_{t+1|t}) \nabla_t$$

1b) i) continuação

$$L(\mu) = \binom{y+r-1}{y} \left(\frac{r}{r+\mu} \right)^r \left(\frac{\mu}{r+\mu} \right)^y$$

$$\Rightarrow l(\mu) = \ln \binom{y+r-1}{y} + r \ln r + y \ln \mu - (r+y) \ln(r+\mu)$$

$$\nabla_t = \frac{\partial l(\mu)}{\partial \mu} = \frac{y_t}{\mu_t} - \frac{r+y_t}{r+\mu_t}$$

$$\frac{\partial \nabla_t}{\partial \mu} = -\frac{y_t}{\mu_t^2} + \frac{r+y_t}{(r+\mu_t)^2}$$

$$\Rightarrow I_{t+1|t} = -E_t \left(-\frac{y_t}{\mu_t^2} + \frac{r+y_t}{(r+\mu_t)^2} \right) = \frac{E(y_t | y_{t-1})}{\mu_{t+1|t}^2} - \frac{r + E(y_t | y_{t-1})}{(r + \mu_{t+1|t})^2}$$

$$\Rightarrow I_{t+1|t} = \frac{1}{\mu_{t+1|t}} - \frac{r + \mu_{t+1|t}}{(r + \mu_{t+1|t})^2} = \frac{1}{\mu_{t+1|t}} - \frac{1}{r + \mu_{t+1|t}}$$

$$\Rightarrow I_{t+1|t} = \frac{r}{\mu_{t+1|t}(r + \mu_{t+1|t})}$$

para $d=1$,

$$\Delta_t = \frac{\mu_t(r + \mu_t)}{r} \left(\frac{y_t}{\mu_t} - \frac{r + y_t}{r + \mu_t} \right) = \frac{(r + \mu_t)y_t}{r} - \frac{\mu_t(r + y_t)}{r}$$

$$\Rightarrow \Delta_t = y_t - \mu_{t+1|t}$$

$$\Rightarrow \mu_{t+1|t} = \omega + \sum_{i=1}^p \alpha_i \mu_{t-i+1|t-i} + \sum_{j=1}^q \beta_j (y_{t-j+1} - \mu_{t-j+1|t-j})$$

ii) Link log

1b) i) (2) link log

$$\log(\mu_{t+1}) = \tilde{\mu}_{t+1} \Rightarrow \mu_t = e^{\tilde{\mu}_t}$$

$$\tilde{\mu}_{t+1} = \omega + \sum_{i=1}^p \alpha_i \tilde{\mu}_{t+1-i} + \sum_{j=1}^q \beta_j \tilde{\Sigma}_{t-j+1}$$

$$\tilde{\nabla}_t = (h_t)^{-1} \nabla_t$$

$$= \left(\frac{\partial \log(\mu_{t+1})}{\partial \mu} \right)^{-1} \nabla_t = \left(\frac{1}{\mu_{t+1}} \right)^{-1} \nabla_t$$

$$\Rightarrow \tilde{\nabla}_t = \mu_{t+1} \nabla_t$$

$$\tilde{I}_{t+1} = (h_t)^{-1} I_{t+1} (h_t)^{-1} \\ = \mu_{t+1}^2 I_{t+1}$$

$$\forall d=1, \tilde{\Sigma}_t = (\tilde{I}_{t+1})^{-1} \tilde{\nabla}_t$$

$$\tilde{\Sigma}_t = \frac{1}{\mu_t^2} \cdot \frac{\mu_t(r+\mu_t)}{r} \cdot \mu_t \left(\frac{y_t}{\mu_t} - \frac{r+y_t}{r+\mu_t} \right) \\ = \frac{(r+\mu_t)y_t}{r\mu_t} - \frac{r+y_t}{r} \\ = \frac{r(y_t - \mu_t)}{r\mu_t}$$

$$\Rightarrow \tilde{\Sigma}_t = y_t e^{-\tilde{\mu}_t} - 1$$

$$\Rightarrow \tilde{\mu}_{t+1} = \omega + \sum_{i=1}^p \alpha_i \tilde{\mu}_{t+1-i} + \sum_{j=1}^q \beta_j (y_{t-j+1} e^{-\tilde{\mu}_{t-j+1}} - 1)$$

$$\Rightarrow \ln \mu_{t+1} = \omega + \sum_{i=1}^p \alpha_i \ln \mu_{t+1-i} + \sum_{j=1}^q \beta_j (y_{t-j+1} \mu_{t-j+1}^{-1} - 1)$$

$$\Rightarrow \mu_{t+1} = \prod_{i=1}^p \mu_{t+1-i}^{\alpha_i} \cdot e^{\omega + \sum_{j=1}^q \beta_j \left(\frac{\mu_{t-j+1}}{y_{t-j+1}} - 1 \right)}$$

Item c) Equação da média com CNO

$$p(y_t|y_{t-1}) \sim NB(\mu_{t|t-1}, r)$$

$$E[y_t|y_{t-1}] = \mu_{t|t-1}$$

$$h(\mu_{t+1|t}) = \tilde{\mu}_{t+1|t}$$

$$\tilde{\mu}_{t+1|t} = m_{t+1|t} + \gamma_{t+1|t}$$

i) Sazonalidade por dummy Harrison & Stevens

1c)i) $p(y_t|y_{t-1}) \sim NB(\mu_{t|t-1}, r)$, $\mu_t > 0$ e $r > 0$
 $E(y_t|y_{t-1}) = \mu_{t|t-1}$
 $\tilde{\mu}_{t+1|t} = \ln \mu_{t+1|t} \Rightarrow \mu_t = e^{\tilde{\mu}_t}$, $\tilde{\mu}_t \in \mathbb{R}$

$\begin{cases} \tilde{\mu}_{t+1|t} = m_{t+1|t} + D_{t+1} \tilde{\delta}_{t+1|t} \\ m_{t+1|t} = \omega + \phi m_{t|t-1} + K^m \tilde{\delta}_t \\ \tilde{\delta}_{t+1|t} = \tilde{\delta}_{t|t-1} + K_t^{\delta} \tilde{\delta}_t \end{cases}$, onde

$\begin{cases} \tilde{\delta}_{t+1|t} = (\delta_{1,t+1|t}, \delta_{2,t+1|t}, \dots, \delta_{12,t+1|t})' \\ D_t = (d_{1t}, d_{2t}, \dots, d_{12t})' \\ K_t^{\delta} = (K_{1t}, K_{2t}, \dots, K_{12t}) \end{cases}$, $d_{jt} = 1$ se $j=t$, e $d_{jt} = 0$ c.c.
 $K_{jt} = K^{\delta}$ se $j=t$ e $K_{jt} = -\frac{K^{\delta}}{11}$ c.c.

$\tilde{\delta}_t = y_t e^{-\tilde{\mu}_{t|t-1}} - 1$

ii) Sazonalidade por trigonométricos

A tendência $m_{t+1|t}$ segue um AR(1) com drift, enquanto a sazonalidade é dada pela soma de funções trigonométricas. É possível escrever as equações dessas componentes não observáveis na forma matricial abaixo.

$$\left\{ \begin{array}{l} \tilde{\mu}_{t+1|t} = (1 \ 1 \ 0 \ 1 \ 0 \ 1 \ 0 \ 1 \ 0 \ 1 \ 0 \ 1) \cdot \begin{pmatrix} m_{t+1|t} \\ \gamma_{1,t+1|t} \\ \gamma_{1,t+1|t}^* \\ \gamma_{2,t+1|t} \\ \gamma_{2,t+1|t}^* \\ \gamma_{3,t+1|t} \\ \gamma_{3,t+1|t}^* \\ \gamma_{4,t+1|t} \\ \gamma_{4,t+1|t}^* \\ \gamma_{5,t+1|t} \\ \gamma_{5,t+1|t}^* \\ \gamma_{6,t+1|t} \end{pmatrix} \\ \\ \begin{pmatrix} m_{t+1|t} \\ \gamma_{1,t+1|t} \\ \gamma_{1,t+1|t}^* \\ \gamma_{2,t+1|t} \\ \gamma_{2,t+1|t}^* \\ \gamma_{3,t+1|t} \\ \gamma_{3,t+1|t}^* \\ \gamma_{4,t+1|t} \\ \gamma_{4,t+1|t}^* \\ \gamma_{5,t+1|t} \\ \gamma_{5,t+1|t}^* \\ \gamma_{6,t+1|t} \end{pmatrix} = \begin{pmatrix} \omega \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} + \begin{pmatrix} \alpha & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & \cos(\lambda_1) & \sin(\lambda_1) & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & -\sin(\lambda_1) & \cos(\lambda_1) & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \cos(\lambda_2) & \sin(\lambda_2) & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & -\sin(\lambda_2) & \cos(\lambda_2) & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \cos(\lambda_3) & \sin(\lambda_3) & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & -\sin(\lambda_3) & \cos(\lambda_3) & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & \cos(\lambda_4) & \sin(\lambda_4) & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & -\sin(\lambda_4) & \cos(\lambda_4) & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & \cos(\lambda_5) & \sin(\lambda_5) & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -\sin(\lambda_5) & \cos(\lambda_5) & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -1 \end{pmatrix} \cdot \begin{pmatrix} m_{t|t-1} \\ \gamma_{1,t|t-1} \\ \gamma_{1,t|t-1}^* \\ \gamma_{2,t|t-1} \\ \gamma_{2,t|t-1}^* \\ \gamma_{3,t|t-1} \\ \gamma_{3,t|t-1}^* \\ \gamma_{4,t|t-1} \\ \gamma_{4,t|t-1}^* \\ \gamma_{5,t|t-1} \\ \gamma_{5,t|t-1}^* \\ \gamma_{6,t|t-1} \end{pmatrix} + \begin{pmatrix} \kappa^m \\ \kappa^\gamma \\ \kappa^\gamma \\ \kappa^\gamma \\ \kappa^\gamma \\ \kappa^\gamma \\ \kappa^\gamma \\ \kappa^\gamma \\ \kappa^\gamma \\ \kappa^\gamma \\ \kappa^\gamma \\ \kappa^\gamma \end{pmatrix} \end{array} \right. \quad \tilde{s}_t, \quad \lambda_j = \frac{2\pi j}{12}$$

Como calculado anteriormente, a função score na forma matricial acima pode ser escrita segundo as equações abaixo.

$$\begin{aligned} \tilde{s}_t &= y_t e^{-\tilde{\mu}_{t|t-1}} - 1 \\ \Rightarrow \tilde{s}_t &= y_t e^{-m_{t|t-1} + \gamma_{t|t-1}} - 1 \end{aligned}$$

Item d) Log da verossimilhança

O log da verossimilhança foi calculado anteriormente em relação aos parâmetros variáveis do modelo para o cálculo da função score. Usando os mesmos resultados e observando a função da log verossimilhança para os parâmetros fixos do modelo e suas restrições, é possível obter os resultados abaixo.

1d) $l(\mu_t, \theta) = \sum_{t=1}^T \left(\ln \left(\frac{y_t + r - 1}{y_t} \right) + r \ln r + y_t \ln \mu_t - (r + y_t) \ln (r + \mu_t) \right)$

Como $r > 0$, usando link log

$l(\tilde{\mu}_t, \theta) = \sum_{t=1}^T \left(\ln \left(\frac{y_t + e^{\psi_t} - 1}{y_t} \right) + \psi_t e^{\psi_t} + y_t \tilde{\mu}_t - (r + y_t) \ln (r + e^{\tilde{\mu}_t}) \right),$

$\theta = (\psi, \omega, \phi, \kappa^m, \kappa, m_1, \delta_{j1}), \quad j = 1, \dots, 12$

$r = e^{\psi}, \quad \psi_2 \in \mathbb{R}$

$\phi = 1 / (1 + e^{-\psi_2}), \quad \psi_2 \in \mathbb{R} \Rightarrow 0 < \phi < 1$

Questão 2

Item a)

$$2) Y \sim f(y|\theta)$$

$$a) E(\nabla) = 0, \quad \nabla = \frac{\partial \ln f(y|\theta)}{\partial \theta}$$

$$E(\nabla) = E\left(\frac{\partial \ln f(y|\theta)}{\partial \theta}\right)$$

$$= \int_{y \in \mathcal{R}} \frac{\partial \ln f(y|\theta)}{\partial \theta} f(y|\theta) dy, \quad \text{suporte de } f(y|\theta)$$

$$= \int_{y \in \mathcal{R}} \frac{1}{f(y|\theta)} \frac{\partial f(y|\theta)}{\partial \theta} f(y|\theta) dy$$

$$= \frac{\partial}{\partial \theta} \int_{y \in \mathcal{R}} f(y|\theta) dy$$

$$= 0, \quad \text{pois } \int_{y \in \mathcal{R}} f(y|\theta) dy = 1$$

Item b)

$$2b) I = E(\nabla \nabla') = -E \left(\frac{\partial^2 \ln f(y|\theta)}{\partial \theta \partial \theta'} \right)$$

$$E(\nabla) = 0 \Rightarrow \int \frac{\partial \ln f(y|\theta)}{\partial \theta} f(y|\theta) dy = 0$$

$$\Rightarrow \frac{\partial}{\partial \theta} \int \frac{\partial \ln f(y|\theta)}{\partial \theta} f(y|\theta) dy = 0$$

$$\Rightarrow \int \left(\frac{\partial}{\partial \theta} \nabla f(y|\theta) + \nabla \frac{\partial f(y|\theta)}{\partial \theta} \right) dy = 0$$

$$\Rightarrow - \int \frac{\partial^2}{\partial \theta \partial \theta'} \ln f(y|\theta) f(y|\theta) dy = \int \nabla \underbrace{\frac{\partial \ln f(y|\theta)}{\partial \theta}}_{\nabla} f(y|\theta) dy$$

$$\Rightarrow -E \left(\frac{\partial^2 \ln f(y|\theta)}{\partial \theta \partial \theta'} \right) = E(\nabla \nabla') \quad ||$$

Questão 3

$$y_t = \mu_t + \epsilon_t, \quad \epsilon_t \sim N(0, \sigma^2)$$

3)

$$\begin{cases} y_t = \mu_{t|t-1} + \varepsilon_t, & \varepsilon_t \sim N(0, \sigma^2) \\ \mu_{t+1|t} = \omega + \sum_{i=1}^p \alpha_i \mu_{t-i+1|t-i} + \sum_{j=1}^q \beta_j \Delta_{t-j+1}, & \Delta_t = (\mathbf{I}_{t|t-1})^{-1} \nabla_t \end{cases}$$

• $p(y_t | y_{t-1}) \sim N(\mu_{t|t-1}, \sigma^2)$

$$\Rightarrow p(y_t | y_{t-1}) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \left(\frac{y_t - \mu_t}{\sigma} \right)^2}$$

$$\Rightarrow \ln p(y_t | y_{t-1}) = \frac{1}{2} \ln 2\pi - \ln \sigma - \frac{1}{2} \frac{(y_t - \mu_t)^2}{\sigma^2}$$

$$\Rightarrow \nabla_t = \frac{y_t - \mu_t}{\sigma^2}, \quad \frac{\partial \nabla_t}{\partial \mu} = -\frac{1}{\sigma^2}$$

$$\Rightarrow \mathbf{I}_{t|t-1} = -E \left(\frac{-1}{\sigma^2} \right) = \frac{1}{\sigma^2}$$

$$\Rightarrow \Delta_t = \frac{1}{\sigma^2} (y_t - \mu_t) = y_t - \mu_{t|t-1}$$

$$\Rightarrow \mu_{t+1|t} = \omega + \sum_{i=1}^p \alpha_i \mu_{t-i+1|t-i} + \sum_{j=1}^q \beta_j (y_{t-j+1} - \mu_{t-j+1|t-j})$$

• $\mu_{t|t-1} = y_t - \varepsilon_t \Rightarrow y_{t-j+1} - \mu_{t-j+1|t-j} = \varepsilon_{t-j+1}$

$$\Rightarrow \mu_{t+1|t} = \omega + \sum_{i=1}^p \alpha_i (y_{t-i+1} - \varepsilon_{t-i+1}) + \sum_{j=1}^q \beta_j \varepsilon_{t-j+1}$$

$$\Rightarrow y_{t+1} = \omega + \sum_{i=1}^p \alpha_i y_{t-i+1} + \sum_{j=1}^q \beta'_j \varepsilon_{t-j+1} + \varepsilon_{t+1},$$

$$\beta'_j = \begin{cases} \beta_j - \alpha_j, & j \leq p \text{ et } j \leq q \\ \beta_j, & p < j \leq q \\ -\alpha_j, & q < j \leq p \end{cases}$$

Questão 4

Item a) Parametrização e momentos da distribuição

$$4) p(y_t | y_{t-1}) \sim \text{Weibull}(\mu, k), \quad k > 0, \mu > 0$$

$$\bullet E[y_t | y_{t-1}] = \lambda \Gamma(1 + 1/k) = \mu \Rightarrow \lambda = \mu / \Gamma(1 + 1/k)$$

$$\Rightarrow E[y_t | y_{t-1}] = \mu$$

$$\bullet V[y_t | y_{t-1}] = \lambda^2 \left(\Gamma(1 + 2/k) - [\Gamma(1 + 1/k)]^2 \right)$$

$$= \frac{\mu^2}{\Gamma^2(1 + 1/k)} \left(\Gamma(1 + 2/k) - \Gamma^2(1 + 1/k) \right)$$

$$= \mu^2 \left(\frac{\Gamma(1 + 2/k)}{\Gamma^2(1 + 1/k)} - 1 \right)$$

$$\bullet S(y_t | y_{t-1}) = \frac{\Gamma(1 + 3/k) \lambda^3}{\sigma^3} - 3 \frac{\mu \sigma^2}{\sigma^3} - \frac{\mu^3}{\sigma^3}$$

$$= \frac{\Gamma(1 + 3/k) \mu^3}{\Gamma^3(1 + 1/k)} - 3 \mu^3 \left(\frac{\Gamma(1 + 2/k)}{\Gamma^2(1 + 1/k)} - 1 \right) - \mu^3$$

$$\mu^3 \frac{(\Gamma(1 + 2/k) - \Gamma(1 + 1/k))^2}{\Gamma^{3/2}(1 + 1/k)}$$

4b) continuação

$$\rightarrow S(y_t|y_{t-1}) = \left(\frac{\Gamma(1+3/k)}{\Gamma^3(1+1/k)} - 3 \frac{\Gamma(1+2/k)}{\Gamma^2(1+1/k)} + 2 \right) \frac{\Gamma(1+1/k)}{\Gamma^2(1+1/k)} \cdot \frac{\Gamma(1+2/k) - \Gamma(1)^{3/2}}{\Gamma^2(1+1/k)} \cdot \frac{1}{\Gamma^2(1+1/k)}$$

$$\bullet K(y_t|y_{t-1}) = \frac{\Gamma(1+4/k)}{\Gamma^4(1+1/k)} - 4 \frac{\Gamma(1+3/k)}{\Gamma^3(1+1/k)} + 6 \frac{\Gamma(1+2/k)}{\Gamma^2(1+1/k)} - 3 \frac{\Gamma(1+1/k)}{\Gamma(1+1/k)} \cdot \left(\frac{\Gamma(1+2/k) - \Gamma(1)^{3/2}}{\Gamma^2(1+1/k)} \right)^2$$

Item b) Equação dos parâmetros

i) GAS

4b)

i) $p(y_t|y_{t-1}) \sim \text{Weibull}(\mu_{t+1}, K_{t+1})$

$$E(y_t|y_{t-1}) = \mu_{t+1}$$

$$\tilde{\mu}_{t+1} = \ln(\mu_{t+1}) \Rightarrow$$

$$\tilde{K}_{t+1} = \ln(K_{t+1})$$

$$\tilde{\mu}_{t+1|t} = \omega^{\mu} + \alpha^{\mu} \tilde{\mu}_{t|t-1} + \beta^{\mu} \tilde{S}_t, \quad \tilde{S}_t = \tilde{I}_{t|t-1}^{-1} \nabla_t$$

$$\tilde{K}_{t+1|t} = \omega^K + \alpha^K \tilde{K}_{t|t-1} + \beta^K \tilde{S}_t$$

$$p(y_t|y_{t-1}) = \frac{K_{t+1}}{\lambda_{t+1}} \left(\frac{y_t}{\lambda_{t+1}} \right)^{K_{t+1}-1} e^{-\left(\frac{y_t}{\lambda_{t+1}} \right)^{K_{t+1}}}, \quad y_t > 0$$

$$= \frac{K_t \Gamma_1}{\mu_t} \left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t-1} e^{-\left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t}}$$

$$\ln p(y_t|y_{t-1}) = \ln(K_t \Gamma_1) + (K_t-1) \ln y_t \Gamma_1 - K_t \ln \mu_t - \left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t}$$

4b) i) continuação

$$\frac{\partial \ell(y_t; \Gamma_{t-1}, \mu_t, K_t)}{\partial \mu_t} = -\frac{K_t}{\mu_t} + \frac{K_t}{\mu_t} \left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t}$$

$$= \frac{K_t}{\mu_t} \left(\left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t} - 1 \right)$$

$$\frac{\partial \ell(y_t; \Gamma_{t-1}, \mu_t, K_t)}{\partial K_t} = \frac{\partial}{\partial K_t} \left(\ln K_t + K_t \ln \Gamma_1 + (K_t - 1) \ln y_t - \right.$$

$$\left. - K_t \ln \mu_t - \left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t} \right)$$

$$\frac{\partial K_t \ln \Gamma_1}{\partial K_t} = \frac{\partial}{\partial K_t} K_t \ln \Gamma \left(1 + \frac{1}{K_t} \right)$$

$$= \ln \Gamma_1 + K_t \frac{\partial \ln \Gamma \left(1 + \frac{1}{K_t} \right)}{\partial K_t}$$

$$= \ln \Gamma_1 + \frac{K_t}{\Gamma_1} \frac{\partial \Gamma \left(1 + \frac{1}{K_t} \right)}{\partial K_t}$$

$$= \ln \Gamma_1 + \frac{K_t}{\Gamma_1} \Gamma \left(1 + \frac{1}{K_t} \right) \left(-\frac{1}{K_t^2} \right)$$

$$= \ln \Gamma_1 - \frac{\Psi_1}{K_t}$$

$$\frac{\partial}{\partial K_t} \left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t} = \frac{\partial}{\partial K_t} e^{K_t \ln \frac{y_t \Gamma_1}{\mu_t}} = \left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t} \left(\frac{\partial K_t \ln \Gamma_1}{\partial K_t} + \ln \frac{y_t}{\mu_t} \right)$$

$$\Rightarrow \frac{\partial \ell(y_t; \Gamma_{t-1}, \mu_t, K_t)}{\partial K_t} = \frac{1}{K_t} + \ln \Gamma_1 - \frac{\Psi_1}{K_t} + \ln y_t - \ln \mu_t - \left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t} \left(\ln \Gamma_1 - \frac{\Psi_1}{K_t} + \ln \frac{y_t}{\mu_t} \right)$$

$$= \frac{1}{K_t} + \ln \frac{y_t \Gamma_1}{\mu_t} \left(1 - \left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t} \right) + \frac{\Psi_1}{K_t} \left(\left(\frac{y_t \Gamma_1}{\mu_t} \right)^{K_t} - 1 \right) //$$

4b) i) continuação

$$\tilde{\nabla}_t = (h)^{-1} \nabla_t$$

$$h(\mu_t) = \int \ln \mu_t = \frac{1}{\mu_t} \quad \text{e} \quad h(K_t) = \int \ln K_t = \frac{1}{K_t}$$

$$\Rightarrow \begin{cases} \tilde{\nabla}_t^\mu = \mu_t \nabla_t^\mu \\ \tilde{\nabla}_t^K = K_t \nabla_t^K \end{cases}$$

$$\Rightarrow \begin{cases} \tilde{\nabla}_t^\mu = K_t \left(\left(\frac{y_t P_1}{\mu_t} \right)^{K_t} - 1 \right), \quad P_1 = P \left(1 + \frac{1}{K_t} \right) \\ \tilde{\nabla}_t^K = 1 + K_t \ln \left(\frac{y_t P_1}{\mu_t} \right) \left(1 - \left(\frac{y_t P_1}{\mu_t} \right)^{K_t} \right) + \Psi_1 \left(\left(\frac{y_t P_1}{\mu_t} \right)^{K_t} - 1 \right), \quad \Psi_1 = \Psi \left(1 + \frac{1}{K_t} \right) \end{cases}$$

↑ digamma

$$\Rightarrow \begin{cases} \tilde{\nabla}_t^\mu = e^{\tilde{K}_t} \left(\left(\frac{y_t P_1}{e^{\tilde{\mu}_t}} \right)^{e^{\tilde{K}_t}} - 1 \right) \\ \tilde{\nabla}_t^K = 1 + e^{\tilde{K}_t} \left(\ln y_t P_1 - \tilde{\mu}_t \right) \left(1 - \left(\frac{y_t P_1}{e^{\tilde{\mu}_t}} \right)^{e^{\tilde{K}_t}} \right) + \Psi_1 \left(\left(\frac{y_t P_1}{e^{\tilde{\mu}_t}} \right)^{e^{\tilde{K}_t}} - 1 \right) \end{cases}$$

ii) CNO

O parâmetro da média condicional é descrito por uma componente de tendência AR(1) e uma componente de sazonalidade por trigonométricos, conforme equações abaixo. A função score foi calculada anteriormente.

4b) ii) $p(y_t | y_{t-1}) \sim \text{Weibull}(\mu_{t|t-1}, \kappa)$, $\mu_t > 0$ e $\kappa > 0$

$$E(y_t | y_{t-1}) = \mu_{t|t-1}$$

$$\tilde{\mu}_{t|t-1} = \ln \mu_{t|t-1} \Rightarrow \mu_t = e^{\tilde{\mu}_t}, \tilde{\mu}_t \in \mathbb{R}$$

$$\tilde{\mu}_{t+1|t} = m_{t+1|t} + \delta_{t+1|t}$$

$$m_{t+1|t} = \omega + \phi m_{t|t-1} + \kappa^m S_t$$

$$\delta_{t+1|t} = \sum_{j=1}^6 \delta_{j,t+1|t}$$

$$\begin{pmatrix} \delta_{j,t+1|t} \\ \delta_{j,t+1|t}^* \end{pmatrix} = \begin{pmatrix} \cos \lambda_j & \sin \lambda_j \\ -\sin \lambda_j & \cos \lambda_j \end{pmatrix} \begin{pmatrix} \delta_{j,t|t-1} \\ \delta_{j,t|t-1}^* \end{pmatrix} + \begin{pmatrix} \kappa^\delta \\ \kappa^\delta \end{pmatrix} S_t, \lambda_j = \frac{2\pi j}{12}$$

Item c) Log da verossimilhança

$$4c) \ell(\tilde{\mu}_t, \theta) = \sum_{t=1}^T \ln p(y_t | y_{t-1}; \tilde{\mu}_t, \kappa)$$

$$= \sum_{t=1}^T \left(\ln \kappa - \kappa \ln \mu_t + \kappa \ln y_t \Gamma_1 - \left(\frac{y_t \Gamma_1}{\mu_t} \right)^\kappa \right), \Gamma_1 = \Gamma \left(1 + \frac{1}{\kappa} \right)$$

Como $\kappa > 0$, usando link log

$$\kappa = e^\psi, \psi \in \mathbb{R}$$

$$\Rightarrow \ell(\tilde{\mu}_t, \theta) = \sum_{t=1}^T \left(\psi - e^\psi \tilde{\mu}_t + e^\psi \ln y_t \Gamma_1 - \left(\frac{y_t \Gamma_1}{e^{\tilde{\mu}_t}} \right)^{e^\psi} \right), \Gamma_1 = \Gamma(1 + e^{-\psi})$$

$$\text{com } \theta = (\psi, \omega, \phi, \kappa^m, \kappa^\delta, m_1, \delta_{i,1}, \delta_{j,1}^*), i=1, \dots, 6$$

$$j=1, \dots, 5$$

Item d) Estimação do modelo

Para estimar o modelo, foi usada uma série diária de armazenamento de energia na região sudeste. A série é disponibilizada em megawatts pelo Operador Nacional de Sistema Elétrico (ONS), conforme os metadados abaixo. Para obter uma série mensal, foi feita a média mensal dos dados diários.

Fonte Base de dados de energia armazenada (EAR) do Operador Nacional do Sistema Elétrico (ONS)


Unidade

Megawatt (MW)


Período da série

01/01/2000 a 01/01/2022

Como pode ser observado nos gráficos, a série apresenta suporte positivo e forte sazonalidade. O modelo escolhido foi a densidade condicional de Weibull com média variante no tempo e parâmetro fixo de forma.



A média condicional foi modelada por uma componente de tendência linear e sazonalidade por dummies. As componentes estimadas podem ser vistas nos resultados abaixo.



PARAMETER SUMMARY

Model parameters:

Parameter type	Value
Constant	11.346
Shape parameter	9.281
Level updating κ	1.695
Seasonal init	1.119
Seasonal updating κ	7.8080e-09

TRAINING SAMPLE MODEL FIT


Variable: armazenamento
Model: TSL005 DCS

	TSL005
Log likelihood	-2657.218
Akaike Information Criterion (AIC)	5324.437
Bias corrected AIC (AICc)	5324.679
Bayesian Information Criterion (BIC)	5342.103
In-sample MSE	1.5120e+08
... RMSE	12296.151
... MAE	7824.871
... MAPE	7.759
Sample size	253
Effective sample size	240
* based on one-step-ahead forecast errors and effective sample size	

Conforme observado nos gráficos acima e nos valores estimados, o parâmetro de atualização da

sazonalidade é próximo de zero, indicando que a sazonalidade possui comportamento praticamente fixo ao longo dos anos. Já o parâmetro de forma da distribuição de Weibull é relativamente alto, indicando uma baixa assimetria nos dados.

Nos resultados do diagnóstico abaixo, é possível observar que o modelo captou bem a dinâmica dos dados, uma vez que os resíduos padronizados apresentam baixa autocorrelação nos lags. O qq-plot e o histograma indicam uma distribuição próxima da normalidade, mas apresentam algumas observações aberrantes nas caudas. Esse resultado pode indicar a necessidade de tratamento de outliers.



O modelo estimado foi comparado com um modelo auto ARIMA na amostra de teste. O ARIMA escolhido foi o ARMA(12,1,1). O modelo score driven apresentou melhor desempenho fora da amostra em termos de RMSE e MAE, conforme tabela abaixo.

